面向 GB1 蛋白质定向进化的科学智能体

作者：于维庭

1. 背景与问题定义

蛋白质定向进化通过反复设计突变、评估性能和筛选候选，寻找具有目标功能的蛋白质变体。本项目选择 GB1 蛋白的结合富集任务，构建由适应度预测模型、大语言模型 Agent 和知识图谱组成的虚拟定向进化系统

项目实现两条适应度预测路线：从零训练 Transformer，以及微调预训练蛋白质模型 ESM2。在此基础上，比较随机推荐、模型直接推荐、普通 Agent 和知识增强 Agent 四种方法，开展三轮候选推荐与真实标签反馈实验

实验重点包括：模型能否识别高 fitness 变体，Agent 如何利用实验反馈调整推荐，以及知识增强是否改善候选选择

2. 数据集与处理

2.1 数据来源与任务

采用 Olson 等人于 2014 年发布的 GB1 单点、双点突变数据集，优化目标为与 IgG 结合相关的筛选富集表现。原始论文

项目使用 gitter-lab/nn4dms 整理的原始计数文件，下载脚本固定了数据版本。每个样本保留完整的 **56 位氨基酸序列**，突变位置覆盖第 2—56 位

野生型序列为：

MQYKLILNGKTLKGETTTEAVDAATAEKVFKQYANDNGVDGEWTYDDATKTFTVTE

数据集共有 **536,963** 条记录，包括 1 条野生型、1,045 条单点突变和 535,917 条双点突变，序列长度均为 56

2.2 Fitness 定义

本实验根据筛选前后的测序计数计算野生型归一化的对数富集值：

$$f(x) = \ln\frac{n_{\text{selection}}(x) + 0.5}{n_{\text{input}}(x) + 0.5} - \ln\frac{n_{\text{selection}}(\text{WT}) + 0.5}{n_{\text{input}}(\text{WT}) + 0.5}$$

其中，0.5 为处理零计数的伪计数。野生型 fitness 为 0，数值越高表示相对野生型的结合富集越强

真实 fitness：由公开实验计数计算的标签，即 label（ground truth）

预测 fitness：预测模型（GB1transformer、ESM2）输出

2.3 数据集划分

固定随机种子为 42，将非野生型记录按 60%、10%、10%、20% 划分

数据划分	样本数	用途
训练集	322,178	模型训练、Agent 初始已知实验输入
验证集	53,696	模型选择

数据划分	样本数	用途
测试集	53,697	最终预测性能评估
候选池	107,392	多轮候选推荐与虚拟实验

Agent 可以查询候选池中的序列和突变信息，真实标签在推荐提交后由独立评估器揭示。测试集不参与 Agent 的推荐过程。

3. 适应度预测模型

3.1 模型设计

两条路线均输入完整蛋白质序列，输出一个 fitness 预测值，使用 MSE 损失进行监督训练。

配置	自训练 Transformer	微调 ESM2
主干模型	4 层 Transformer Encoder	ESM2，12 层、约 35M 参数
输入表示	氨基酸 embedding＋位置 embedding	ESM2 tokenizer 与预训练表示
训练方式	从零训练	主干和回归头共同微调
学习率	3×10^{-4}	2×10^{-5}
Batch size	256	32
Epoch	30	12
最佳模型选择	验证集 Spearman	验证集 Spearman

自训练 Transformer 的隐藏维度为 128，注意力头数为 4。模型通过双向注意力编码序列，对全部位置平均池化，再通过回归头预测 fitness。

ESM2 使用 facebook/esm2_t12_35M_UR50D，通过 Hugging Face Trainer 完成全参数微调。

3.2 训练与测试结果

Transformer 的验证 MSE 从第一轮的 0.6198 降至第 30 轮的 0.2047，验证 Spearman 从 0.9371 提升至约 0.9796，后期逐渐趋于稳定。验证集的 Spearman 结果，最终选择第 26 轮权重。

ESM2 第一轮验证 MSE 为 0.3007，第 8 轮达到最佳验证 Spearman 0.9801，之后出现小幅波动，最终恢复第 8 轮权重进行测试。

模型	测试 MSE	Spearman	Pearson	Top-100 命中率	推荐 Top-100 真实 fitness 均值
Transformer	0.2098	0.9800	0.9813	0.67	1.5895
ESM2	0.1879	0.9804	0.9818	0.61	1.5759

Top-100 命中率定义为预测排名前 100 与真实排名前 100 的样本交集大小除以 100。

ESM2 的整体回归误差更低，相关系数略高；Transformer 的 Top-100 命中率和筛选均值更高。这说明整体预测精度与高分区域的筛选能力并不完全一致，定向进化任务需要同时关注回归指标和候选筛选指标。

4. 科学 Agent 设计

Agent 使用 deepseek-flash 驱动。通过 LangChain 的 Agent 接口构建 LangGraph 工具调用循环，MCP 提供数据查询、模型预测和知识检索能力。

MCP 工具	功能
inspect_known_data	查询已知实验统计及高分变体

MCP 工具	功能
find_candidates	查询尚未实验的候选序列
predict_fitness	调用 Transformer 或 ESM2 预测 fitness
query_position_knowledge	查询位点及其替换证据
query_mutation_knowledge	查询突变的单点和组合背景
compare_residue_properties	比较氨基酸理化性质

Agent 在每轮中自主决定查询哪些位点、比较哪些候选以及如何调整推荐。Agent 工作流程为：

读取已知实验与历史反馈
↓
提出假设、查询候选、调用模型预测
↓
比较候选并提交 Top-10 与推荐理由
↓
查看真实 fitness，形成下一轮反馈

Agent 共进行 3 轮实验，每轮推荐 10 个突变候选，再查看这些候选的真实 fitness。前两轮结束后，Agent 对比预测值与真实值，总结结果，并据此调整下一轮推荐。第三轮结束后，程序汇总三轮候选及其预测值、真实值和评价指标

Agent 从候选池中选择尚未推荐过的突变体，调用模型预测后提交推荐。程序检查候选和预测记录是否有效，通过后再读取对应的真实 fitness，供 Agent 分析

交互界面采用 React 和 FastAPI，能够输入野生型序列与问题、开启知识增强、查看回答和工具调用，并展示最终候选及推荐依据。UI 使用自训练 Transformer 的 MCP 预测接口。

5. 知识增强方法

使用 NetworkX 构建轻量知识图谱，组织位点、氨基酸、突变和变体之间的关系：

位点 → 野生型残基
位点 → 可选突变
突变 → 原残基 / 目标残基
变体 → 包含的突变
变体 → 实验 fitness、序列和证据来源

氨基酸性质采用 AAindex 中的疏水性、极性、体积和电荷编码，分别对应 KYTJ820101、GRAR740102、GRAR740103、KLEP840101。

实验知识仅来自训练集和 Agent 一轮推荐后查询到的真实 fitness 分数。

当两个单点及其双点组合的观测均可用时，工具计算：

$$\Delta f = f_{AB} - f_A - f_B$$

通过比较双点突变的真实 fitness 与两个单点分数之和，Agent 可以了解两个突变组合后的效果。

普通 Agent 与知识增强 Agent 共用基础提示词和预测工具，知识增强组额外获得图谱查询工具及相关使用说明。

6. 虚拟定向进化实验结果

6.1 实验设置

两条模型路线分别比较四种方法，共八组实验。每组运行三轮，每轮选择 10 个候选，组内累计 30 个不重复变体。

方法	候选选择方式
随机推荐	从候选池无放回随机抽样
模型直接推荐	对全部候选评分，按预测分数排序选择
普通 Agent	根据已知实验、假设和预测结果决定推荐
知识增强 Agent	在普通 Agent 基础上加入知识图谱查询

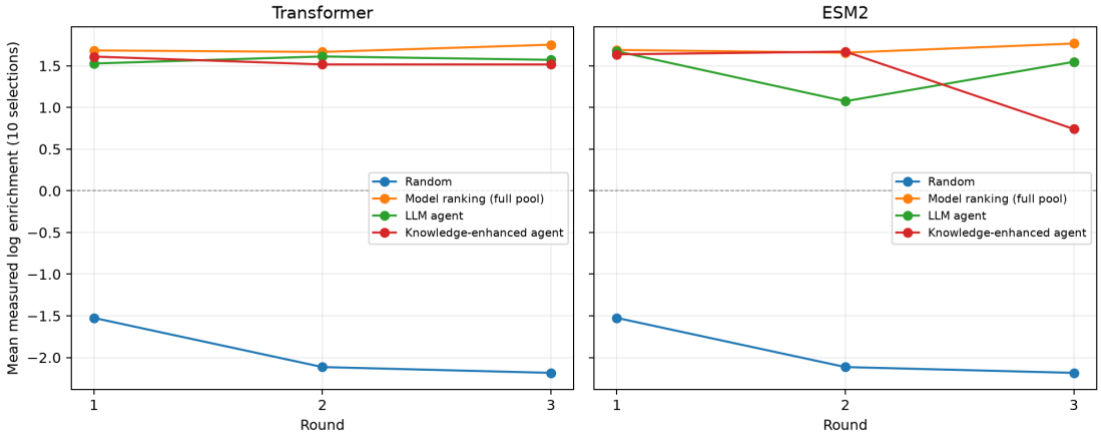
各组使用相同的候选池和真实标签查询数量。预测模型在三轮中保持固定，Agent 根据新反馈调整选择策略。模型直接推荐覆盖整个候选池，Agent 通过定向查询比较部分候选

6.2 四种方法对比

下表均为推荐候选的真实 fitness。

模型	方法	第一轮均值	第二轮均值	第三轮均值	三轮总体均值	最佳值
Transformer	随机推荐	-1.5250	-2.1147	-2.1843	-1.9413	1.3397
Transformer	模型直接推荐	1.6844	1.6661	1.7531	**1.7012**	**2.5295**
Transformer	普通 Agent	1.5274	1.6120	1.5713	1.5702	2.0525
Transformer	知识增强 Agent	1.6105	1.5163	1.5161	1.5476	1.8128
ESM2	随机推荐	-1.5250	-2.1147	-2.1843	-1.9413	1.3397
ESM2	模型直接推荐	1.6900	1.6571	1.7672	**1.7048**	2.0109
ESM2	普通 Agent	1.6739	1.0750	1.5476	1.4322	**2.5295**
ESM2	知识增强 Agent	1.6372	1.6703	0.7409	1.3495	2.0525

两条路线的随机组使用相同候选池和随机种子，因此选中相同候选，真实 fitness 也相同。



三轮推荐候选的平均真实 fitness

模型直接推荐在两条路线中都取得最高的总体均值，分别为 1.7012 和 1.7048。两类 Agent 均明显优于随机推荐，但没有稳定超过模型直接筛选

Agent 配合 ESM2 找到了 fitness 为 2.5295 的变体，高于该模型直接推荐组的最佳值 2.0109，说明其候选选择能够发现模型排序之外的高分变体；同时，其整体均值较低，反映出单个最佳发现与整批推荐质量之间存在差异

Agent 会根据前一轮候选的 fitness 值调整下一轮推荐，但是推荐效果没有稳定的提高，说明后续推荐中，Agent 可能会引入较弱的推荐项

6.3 每轮 Top-10 推荐示例

下表展示 Transformer 普通 Agent 的三轮推荐。括号内为真实 fitness，序号为提交顺序。

序号	第一轮	第二轮	第三轮
1	A24Y:K50R（1.758）	A24Y:K50T（1.384）	V21A:A24W（2.018）
2	A24Y:V29H（1.585）	A24Y:K50V（1.719）	V21F:A24Y（1.685）
3	A24W:T51K（1.650）	A24Y:K50I（1.650）	V21M:A24Y（1.272）
4	A24Y:Q32K（1.759）	Q2F:A24H（1.623）	A24Y:K50L（1.630）
5	E19W:A24W（1.399）	A24H:T51R（1.464）	A24Y:D40F（1.607）
6	E19Y:A24H（1.284）	V21W:A24H（1.421）	A24W:D40W（1.601）
7	A24F:T51W（1.335）	V21A:A24Y（2.052）	A24Y:E42K（1.575）
8	A24H:T51H（1.610）	A24W:K50W（1.977）	A24Y:A48W（1.584）
9	A24W:V29Q（1.326）	A24H:K50Q（1.464）	A24Y:D47Y（1.948）
10	A24Y:T53R（1.569）	A24F:Q32K（1.367）	A24Y:G38I（0.794）

6.4 推荐位点分布

每组实验三轮共推荐 30 条不同突变序列，实验中，推荐明显集中于第 24 位，两组模型直接推荐组的 30 个候选均包含该位点；Transformer 的普通与知识增强 Agent 组也均为 30 个，ESM2 普通 Agent 为 28 个，知识增强 Agent 为 30 个

除第 24 位外，各组推荐涉及较多的突变位点有所不同：Transformer 普通 Agent 主要涉及第 50、21、51 位，知识增强 Agent 主要涉及第 40、50、37、51 位；ESM2 普通 Agent 主要涉及第 19、51、2 位，知识增强 Agent 主要涉及第 40、51、53 位

这表明模型和 Agent 都识别到了第 24 位相关组合的高分信号，而不同推荐策略主要体现在第二位点及替换残基的选择上

7. 成功案例、失败案例与 Agent 行为分析

7.1 成功案例：发现高分组合

ESM2 普通 Agent 在第一轮推荐了 E19Q:A24Y，模型预测为 **1.6750**，真实 fitness 为 **2.5295**。

Agent 根据已知的第 19 位与第 24 位高分组合，提出改变第 19 位残基、保留 A24Y 背景的候选。该结果高于模型预测，说明基于已知实验进行局部假设扩展，可以补充单纯预测排序。

该变体完整序列为：

MQYKLILNGKTLKGETTTQAVDAYTAEKVFKQYANDNGVDGEWTYDDATKTFTVTE

7.2 反馈如何影响下一轮推荐

Transformer 普通 Agent 在第二轮发现 V21A:A24Y 的真实 fitness 为 **2.0525**，高于预测值 **1.4254**。阶段总结随后提出围绕这一组合探索邻近变体。

第三轮实际推荐了 V21A:A24W、V21F:A24Y 和 V21M:A24Y，对应真实 fitness 分别为 **2.0176、1.6852、1.2718**。

这一过程体现了“发现高分组合—提出背景替换假设—设计候选—获得反馈”的连续决策，但结果说明相邻变体的效果仍有明显差异。

7.3 知识增强的具体作用

ESM2 知识增强 Agent 在第二轮查询第 21 位知识，并结合已知 V21A:A24H 组合，推荐 V21A:A24Y。

已知实验中，V21A 单点 fitness 约为 -0.0115，A24H 单点约为 1.3137，二者组合为 2.2859。Agent 据此提出检验 V21A 的组合收益能否延伸到 A24Y 背景。最终候选预测为 **1.6285**，真实值为 **2.0525**。

知识图谱提供了训练集中 V21A、A24H 及其组合的真实 fitness。Agent 参考这些已知结果，提出新的候选 V21A:A24Y，再调用 ESM2 预测它的 fitness

具体来说，单独进行 V21A 突变时，fitness 接近野生型；但它与 A24H 同时出现时，分数比两个单点分数之和高约 0.98。因此，Agent 有理由继续研究这两个位置的组合，而不是仅根据 V21A 的单点分数放弃它。

Agent 随后保留 V21A，将第 24 位的替换从 H 改为 Y，检验新组合是否也能获得较高的 fitness。真实结果为 2.0525，说明这次推荐找到了一个高分组合。知识图谱在这个过程中帮助 Agent 从已有实验中找到值得继续尝试的方向，新候选的效果仍通过真实实验数据判断。

7.4 失败案例：Agent 为什么仍然推荐低分候选

ESM2 知识增强 Agent 第三轮推荐的平均真实 fitness 从上一轮的 **1.6703** 降至 **0.7409**。其中，A24W:Q32P 的模型预测为 **-1.6727**，Agent 怀疑模型低估了它，仍将其列入推荐。最终真实 fitness 为 **-2.2729**，没有支持 Agent 的猜测。

从推荐理由、工具调用和上一轮总结来看，这次选择存在三个问题。

第一，Agent 将部分推荐机会用于检查模型，而不是优先寻找高分候选。 第二轮结束后，Agent 发现预测值与真实值存在差异，在下一轮计划中提出同时选择高分和低分候选，检查模型是否预测准确。第三轮沿用了这一计划。提示词中强调了提出并检验假设，但没有明确高 fitness 筛选与模型检查之间的优先级，使 Agent 有空间将检查模型作为推荐目的。对于本次以推荐 fitness 为主要评价指标的实验，这种选择降低了整批候选的表现。

第二，Agent 没有查询与该候选直接相关的负面结果。 训练集中已有 Q32P 单点的真实 fitness，约为 **-3.9791**，但第三轮的知识查询集中于第 24、40、51、21 位，没有查询第 32 位。Agent 随后在推荐理由中写出“Q32P 无单点标签”，把尚未查询到的信息当成了不存在的信息。如果先查询 Q32P，就能在决策时同时考虑模型低分和已有单点低分这两项证据。

第三，Agent 将其他替换的成功经验推广到了 Q32P。 推荐理由引用了第 32 位替换为 N、R、L 时的一些高分组合，据此猜测替换为 P 也可能表现较好。但这些记录对应不同残基，部分还使用不同的第 24 位替换，不能直接说明 A24W:Q32P 也值得优先推荐。模型在之前的候选上出现过误差，也不足以说明这个低分预测就是错误的。

这个案例说明，问题不只是预测模型不够准确。模型已经给出了低分判断，Agent 却在没有查全相关证据的情况下选择了该候选。后续应在任务和轮间总结中明确优先寻找高 fitness 变体，并要求 Agent 在推荐低预测分数候选前，查询相关突变的已有实验结果，说明支持这次选择的具体依据。

7.5 Agent 的实际贡献

工具轨迹和轮间记录表明，Agent 参与了位点分析、假设生成、候选设计和反馈修订，决策并非始终按预测分数排序。

本次实验中，Agent 的主要作用体现在形成可解释的探索过程、发现部分被低估的候选，以及提出后续实验问题。与此同时，模型直接筛选的总体均值更高，说明 Agent 还需要更好地协调假设探索与高 fitness 推荐目标。

8. 总结与改进方向

本项目完成了 GB1 数据处理、两条适应度预测路线、科学 Agent、知识图谱、三轮虚拟实验和交互式展示。

两条模型的测试 Spearman 均约为 0.98。ESM2 的整体回归误差更低，Transformer 在测试集 Top-100 筛选指标上表现更好。候选推荐实验中，模型直接推荐取得最高总体均值；Agent 能利用实验反馈提出新的候选，但知识增强没有带来稳定的 fitness 提升。

后续改进可集中在三个方面：

- **明确推荐目标：** 区分提高 fitness 的候选与用于验证假设的探索候选，控制低分探针对最终推荐的影响。
- **完善证据检索：** 提交候选前检查相关单点和组合记录，减少遗漏已有负面证据的情况。
- **加强高分区域排序：** 针对模型低估高收益组合、候选间排序不准确的问题，改进训练目标和反馈利用方式。

参考资料与工具使用说明

1. Olson, C. A., Wu, N. C., & Sun, R. (2014). *A Comprehensive Biophysical Description of Pairwise Epistasis throughout an Entire Protein Domain*. Current Biology, 24(22), 2643–2651。论文链接
2. GB1 计数整理数据来自 gitter-lab/nn4dms，下载版本为 434e354828f306cbb6796033ef1169cbe5207350。
3. 预训练模型采用 Meta 发布的 ESM2 35M，相关研究为 Lin 等人的 Evolutionary-scale prediction of atomic-level protein structure with a language model。
4. 氨基酸理化性质采用 AAindex 中的 KYTJ820101、GRAR740102、GRAR740103 和 KLEP840101。
5. 实现使用 PyTorch、Transformers、LangChain、LangGraph、MCP、NetworkX、React 和 FastAPI。DeepSeek 用于实验中的 Agent 决策及阶段总结； Codex 用于解释考核题目、代码实现指导、代码检查、问题修复、辅助报告整理以及格式调整。